

人类活动轨迹的分类、模式和应用研究综述

李 婷^{1,2}, 裴 韬¹, 袁烨城¹, 宋 辞¹, 王维一^{1,2}, 杨格格^{1,2}

(1. 中国科学院地理科学与资源研究所 资源与环境信息系统国家重点实验室, 北京, 100101;

2. 中国科学院大学, 北京, 100049)

摘 要:各种传感器的应用与发展,如车载GPS、手机、公交卡、银行卡等,记录了人类的活动轨迹。这些海量的人类活动轨迹数据中蕴含着人类行为的时空分布模式。通过对这些轨迹的研究可以挖掘个体轨迹模式,理解人类动力学特征,进而为对轨迹预测、城市规划、交通监测等提供支持。因此,研究各类传感器记录的人类活动轨迹数据成为当前的研究热点。本文对人类活动轨迹的获取与表达方式进行剖析,并将人类的活动轨迹按照采样方式和驱动因素的不同分为基于时间间隔采样、基于位置采样和基于事件触发采样等3类轨迹数据。由于各类轨迹数据均由起始点、锚点和一般节点等构成,因而将轨迹模式挖掘的研究按照锚点、出行范围、形状模式、OD流模式、时间模式等进行组织,研究成果揭示人类活动轨迹在时间、空间的从聚模式、周期性等特点。在此基础上,将人类活动轨迹在城市研究中的应用,按照用户轨迹预测、城市动态景观、城市交通模拟与监控、城市功能单元识别以及城市中其他方面的研究应用进行系统综述,认为人类活动模式挖掘是城市规划、城市交通、公共安全等方面应用的基础。

关 键 词:轨迹特征;活动模式;轨迹数据

doi: 10.11820/dlkxjz.2014.07.009

中图分类号:P237

文献标识码:A

1 引言

随着传感器技术、无线通信和网络技术的成熟,手机通话、无线上网、车载GPS(Global Positioning System)、智能卡(公交卡、银行卡)、监控摄像网络等泛在传感器被大量使用,一方面,人们的生活变得更加快捷、舒适、高效;另一方面,它们也在悄然颠覆着人类的生活方式。在科技与人类博弈的过程中,双方都在被对方深刻地改变着。这一过程就好比杠杆,一端是科技试图通过支点撬动人类的生活方式,另一端生活方式的变化也不断刺激着科技的创新。在这场充满创新、反馈和博弈的杠杆游戏中,其关键的支点正是人类的行为模式,它不仅是人类活动的表象特征,同时也是科技创新的动力。例如,人类出行模式的两端是“交通科技、交通规划”和居民出行方式;而人类消费模式的两端是“电子商务、金融创新、商业策略”和“居民的消费方式”;交友模式联系的是“通讯技术、社交网络”和

“人类的情感需求”等。人类行为模式正成为研究社会科学科技之间的纽带,其重要性不言而喻。

过去由于科技的局限,海量的个体信息获取成本巨大、时效性低,因此无法有效获取大量的人类行为数据进行研究。而在当今的网络时代,人们的工作、生活、消费、旅行等行为正在不断通过泛在传感器的使用而被完整和系统地记录下来并形成数据,这为研究人类行为模式提供了前所未有的机遇和挑战。近年来,相关研究已经预示这一时代的到来,相关成果不仅对已有理论方法产生了巨大的变革,同时也在城市规划、交通设计、商业选址、信息服务等应用领域产生了积极而深刻的影响。为揭示相关研究在人类行为研究理论和应用方面的进展,以人类活动轨迹为核心,从以下几个方面展开综述:①从轨迹数据的获取与表达角度对其进行分类;②介绍轨迹数据的研究现状,详细阐述轨迹的特征与模式;③介绍人类活动轨迹数据在城市研究中的应用,最后总结全文并对未来研究方向提出展望。

收稿日期:2014-03;修订日期:2014-06。

基金项目:国家自然科学基金项目(41171345,41231171);国家863计划项目(2012AA12A403)。

作者简介:李婷(1990-),女,新疆乌鲁木齐人,硕士研究生,主要研究方向为时空数据挖掘,E-mail: lit@lreis.ac.cn。

通讯作者:袁烨城(1983-),男,浙江嵊州人,博士,主要从事空间语义分析方面的研究,E-mail: yuanync@lreis.ac.cn。

2 轨迹数据分类

轨迹数据是对移动对象的运动过程采样得到的数据,通常包含采样位置、时间、运动速度等属性信息。将采样点按照一定时间尺度排序便形成了移动对象的轨迹(Li et al, 2007)。根据采样方式和驱动因素的不同,将轨迹数据分为以下3类:①基于时间采样的轨迹数据,即按等时间间隔对移动对象进行采样形成的轨迹;②基于位置采样的轨迹数据,即移动对象位置发生变化即被记录而形成的轨迹;③基于事件触发的轨迹数据,即移动对象触发传感器事件后而被记录下来形成的轨迹。以下按照不同的轨迹类型进行阐述。

2.1 基于时间采样的轨迹数据

基于时间采样的轨迹是等时间间隔记录移动对象的信息,或扫描全局通过反演移动对象位置而获得的数据,前者如车载GPS数据、动物迁徙数据,后者如飓风数据、涡旋数据等。图1a为基于时间采样的轨迹数据示例。

基于时间采样的轨迹可用以下模型表达,即以等长的时间间隔记录移动个体的位置(Nanni, 2002)。

$$Tr = \{(X_1, Y_1, St), (X_2, Y_2, St + \Delta T), \dots, (X_n, Y_n, St + (n - 1) \times \Delta T)\} \quad (1)$$

式中: Tr 代表一条时空轨迹, St 代表起始时刻, ΔT 代表时间记录间隔, 序列中 $(X_n, Y_n, St + (n - 1) \times \Delta T)$ 代表在 $St + (n - 1) \times \Delta T$ 时刻, 轨迹对象在二维空间的位置为 (X_n, Y_n) 。

基于时间采样的轨迹数据具有数据量大、覆盖范围广的特点。但未考虑数据的代表性,会造成数

据冗余、数据遗漏,如车载GPS在车辆状态没有发生变化时仍然收集数据,传输过程中往往出现传感器信号丢失以致数据遗漏,且轨迹数据依赖局限于交通路网。

2.2 基于位置采样的轨迹数据

基于位置采样的轨迹是当采样对象位置发生变化时记录其位置、时间、属性信息而获得的数据,如居民出行调查、人口迁徙统计数据等。图1b为基于位置采样的轨迹数据示例。

基于位置变化采样的轨迹可由移动对象位置变化的节点序列表示(Nanni, 2002),模型表达如式(2),即以离散位置变化节点记录移动个体的轨迹信息。

$$Tr = \{(X_1, Y_1, T_1), (X_2, Y_2, T_2), \dots, (X_n, Y_n, T_n)\} \quad (2)$$

式中: $X_n \neq X_{n+1}$, 且 $Y_n \neq Y_{n+1}$, 且 $T_1 \neq T_n$; Tr 代表时空轨迹,该序列中 (X_n, Y_n, T_n) 代表在 T_n 时刻, 轨迹对象在二维空间的位置为 (X_n, Y_n) 。

基于位置采样的轨迹数据以移动对象的位置变化为关注重点,具有属性信息丰富、轨迹位置变化详细等特点。但这类数据收集主要依靠人工操作,缺乏自动采集装置,导致数据整理过程耗时耗力、调查范围有限、更新周期长、空间位置需要二次匹配等一系列问题。

2.3 基于事件触发采样的轨迹数据

基于事件触发采样的轨迹是移动对象触发传感器事件后,移动对象的位置、时间及其他属性信息被记录下来的数据,如手机通话,手机连接wifi热点,公交卡、银行卡等智能卡刷卡,用户签到等事件触发手机基站、路由器、刷卡机、网络等工作,从而形成手机通话数据、wifi定位数据、公交车或银行




图1 采样轨迹数据
Fig.1 Sampling of trajectory data

卡刷卡数据、签到数据等。若移动对象未触发传感器事件,其移动轨迹则不能被记录。图1c为基于事件触发采样的轨迹数据示例。

虽然移动对象的时空轨迹是连续的,但只有移动对象触发传感器事件发生时,位置、时间信息才有记录,因此此类时空轨迹可以由一组离散的时空记录点序列表示,如式(3)所示:

$$Tr = \{(X_1, Y_1, T_1), (X_2, Y_2, T_2), \dots, (X_n, Y_n, T_n)\} \quad (3)$$

式中: $T_i \neq T_n$, (X_n, Y_n) 与 (X_{n+1}, Y_{n+1}) 有可能相等; Tr 代表一条时空轨迹,该序列中 (X_n, Y_n, T_n) 代表在 T_n 时刻,轨迹对象二维空间的位置为 (X_n, Y_n) 。

基于事件触发采样的轨迹数据具有数据量大、覆盖范围广、更新周期短、采样对象具有代表性等特点。但此类轨迹数据记录的位置不一定是移动对象的真实位置,导致轨迹数据的空间分辨率不高。如手机通话事件的位置是用基站服务范围(以基站为标识点的 Voronoi 多边形)近似表示,位置精度取决于基站的密集程度,且只有传感器事件被触发时才记录移动对象的相关信息,无法勾勒移动对象详尽的轨迹信息,只是人类行为活动中的快照。

3 轨迹组成与模式

轨迹是研究对象随时间的推移在空间上移动

所经过的路径,由节点与节点之间的线组成,节点就是轨迹的采样点,其中包括起点、锚点、终点,如图2所示。目前轨迹的模式研究主要集中在锚点、出行范围、轨迹的形状、OD流、时间等方面。

3.1 轨迹组成

3.1.1 锚点

锚点是轨迹中移动对象停留时间较长的节点(Golledge et al, 1997),也代表空间对象频繁到访的地点。锚点的从聚模式反映空间对象的时空分布规律及用户工作状态,可用于预测用户位置。当前针对锚点的研究主要有:①轨迹中锚点的识别;②锚点中用户兴趣点的发现;③以锚点数目和到访频率为特征的轨迹类型判别。

(1) 目前锚点识别主要利用停留时间与到访频度的方法,为发现用户兴趣点或有意义的地点提供支持。以手机通话数据为例,Phithakkitnukoon等(2010)用时间阈值的方法从美国马萨诸塞州100万匿名用户的通话记录中提取锚点,进而分析用户的活动模式。Kang等(2010)利用到访频度的方法从中国某城市80多万匿名用户的通话记录中提取频繁到访的地点。

(2) 分析锚点的从聚模式可以识别不同类型的锚点,从而发现用户兴趣点,如工作地或居住地等。Calabrese等(2013)对美国马塞诸塞州100多万手机通话数据,使用特定时间与格网法划分研究

表1 不同轨迹的主要特点

Tab.1 Main characteristics of different trajectory data

数据类型	采样方式	优缺点	数据实例	代表性研究
基于时间采样的 轨迹数据	1.等时间间隔收集移 动对象的信息	优点:数据量大、覆盖范围广 缺点:采样不具代表性,大量	1.车载GPS数据、动 物迁徙数据	1. 申悦等, 2013; Garcia et al, 2010; Guo et al, 2010; Liu et al, 2010; Zheng et al, 2010
	2.扫描全局、记录移动 对象的信息	数据冗余,传感器信号丢失以 致数据遗漏	2. 飓风数据、涡旋数 据	2. Wang et al, 2003; Camargo et al, 2004
基于位置采样的 轨迹数据	移动对象位置有变化 时记录其信息	优点:属性信息丰富、轨迹位 置变化详细 缺点:主要依靠人工操作,缺 乏自动采集装置	居民出行调查、人口 迁徙统计数据	邓毛颖等, 2000; 曲大义等, 2001; 马静等, 2009; Kwan, 1999; Guo, 2009; Simini et al, 2012; Pei et al, 2013
基于事件触发的 轨迹数据	移动对象触发传感器 事件后,移动对象的信 息被记录下来	优点:数据量大、覆盖范围广、 更新周期短、采样具有代表性 缺点:记录的位置不一定是移 动对象真实位置,只有传感器 事件被触发时移动对象的相 关信息才被记录,无法勾勒出 移动对象详尽的轨迹信息	手机通话数据、刷卡 数据、wifi定位数 据、签到数据	龙瀛等, 2012; Ratti et al, 2006; Rekimoto et al, 2007; Gonzalez et al, 2008; Kang et al, 2010; Yuan et al, 2011; Sun et al, 2012; Liu et al, 2014




图2 轨迹的组成

Fig.2 Composition of a trajectory

区,挖掘识别用户的居住地。Ahas等(2010)利用爱沙尼亚的手机数据,使用通话起始时间与标准差分布的方法,挖掘识别对手机用户有意义的位置(如工作地或居住地),为基于位置服务(Location Based Service, LBS)市场的发展(如开发个性化的位置感知广告),地理基础设施建设(如优化无线电覆盖率和其他网络服务),以及城市规划、交通管理等方面提供支持。

(3) 轨迹中锚点数目和到访频率特征反映不同类型的行为性质,如个体工作性质差异。Kang等(2010)发现个体轨迹中锚点数目少且到访频率高的用户,工作地较为固定,而个体轨迹到访锚点数量多且到访频率低的个体工作地不固定。

目前对人类活动轨迹锚点的研究主要集中在单个兴趣点(如工作地等),对相互关联的多兴趣点序列的研究不足。而对兴趣点序列(同时考虑居住地、工作点、特定地点等)的轨迹聚类,可以进一步识别具有特定特征(职业类别)的群体轨迹类型。

3.1.2 出行范围

轨迹出行范围有两层含义:①个体日常出行离开住所的距离;②轨迹总长度。本文关注前者,它对于理解个体行为模式、评估个体出行成本,进而了解城市规模具有重要意义。当前针对个体轨迹出行范围的研究主要集中在以下3个方面:①出行范围与出行人数间的关系;②出行范围、频率与出行目的间的关系;③不同特征群体出行范围的差异。

首先,个体轨迹出行范围与出行人数间的关系,可以反映城市规模大小、居民生活水平和交通成本的高低。Kang等(2010)利用黑龙江省手机通

话数据,使用回旋半径描述用户轨迹的出行范围,发现出行范围在一定范围内时,出行人数上升,超过此范围后,出行人数下降。其次,用户不同的出行目的导致出行范围不同、关注重点(准时、最短路程)不同,因此需合理规划交通发展策略。邓毛颖等(2000)分析广州市1984、1998年居民出行调查数据,发现生活购物为目的的出行范围最短,上班出行范围最远,上学与娱乐介于两者之间。罗典等(2010)对广州市1984年与2005年前后两次居民出行调查数据进行分析,发现城市发展中居民出行次数有所增加,其中购物、娱乐为目的的出行频率增加,而通勤、探亲出行的频率减少。然后,对比不同性别、年龄段的人群出行范围,发现不同特征群体出行范围具有显著差异(Kwan, 1999; Kwan et al, 2003):①女性的平均活动半径略高于男性(Yuan et al, 2011);②青年和中年人的出行范围远高于青少年和老年群体(Kang et al, 2010);③与年轻人(19~64岁)相比,老年(65岁以上)人群出行更依赖私人交通工具,且出行距离更短,出行时间更少,尤其是女性(Demetra et al, 2003)。

对轨迹出行范围的研究,目前只关注出行距离与出行人数、频次、目的之间的关系,没有结合不同的轨迹特征,如轨迹形状、时间、兴趣点语义特征等进行聚类,以发现不同的日常出行模式,如白天出行,全天在家,夜出未归,长、短距离出行等。

3.2 轨迹模式

3.2.1 形状模式

轨迹形状指轨迹采样点组成的时空路径的形状。轨迹形状对于识别移动对象间相似特征及异常情况等具有重要意义。当前轨迹形状的研究主要有以下两类:

(1) 个体相似轨迹识别。轨迹形状可以反映个体的职业特征、出行模式,如轨迹形状在工作日具有高度的时空规律,在非工作日较杂乱的个体具有固定的全职工作及工作单位,而轨迹形状在一周中不规则的个体,相对工作性质不稳定、工作单位不固定(Kang et al, 2010)。从个体轨迹形状中归纳出共同特征,可以将轨迹形状个体研究扩展到群体研究。Yuan等(2013)提出时空编辑距离的方法对手机通话数据中不同的用户群体进行分类,识别相似用户轨迹。

(2) 异常轨迹模式探测。从中可以发现新现象或异常现象,探究形成原因,找出解决方案。Zhang

等(2011)提出 iBAT/iBOAT 算法对出租车轨迹数据分析,识别出租车绕路模式。Liu 等(2010)对深圳市 480 万条出租车轨迹数据进行研究,发现时间利用率最大(开车速度更快,对交通状况和道路网络更了解)的司机收益最高,而偏向绕路的司机收入反而不是最高。

目前轨迹形状的研究未考虑语义特征对模式的影响,如轨迹形状类似,但经过地点语义不同,其轨迹模式的含义不同。另外,异常模式都是事后发现,时间滞后导致无法及时响应进行处理,对异常模式的预判及响应研究不足。

3.2.2 OD 流模式

OD(Origin-Destination)流指轨迹中起点到终点的流动性特征,其中 O 表示出行起点,D 表示出行终点。OD 流从统计的角度反映移动对象的活动和群体轨迹的动态特征。当前研究主要集中在 O、D 位置和 OD 流的移动性两方面。①O、D 位置的研究关注轨迹起止点位置特征。出租车数据 OD 点在乘客的角度相当于上车点、下车点。Veloso 等(2011)发现上车点和下车点密度的空间分布,可识别城市主要位置(如火车站、飞机场等)。Guo 等(2012)将上车点、下车点位置进行聚类划分,得到不同时段上车比下车高或下车比上车高的区域,并推测该区域的成因。童晓君等(2012)对出租车上车点、下车点进行聚类分析,发现了节假日与工作日的上车、下车热点区域。②OD 流移动性研究包括 OD 流的可视化、基于 OD 流的社区结构发现等。Guo(2009)对美国人口迁移数据进行分析得到可视化流,揭示人口迁移规律,发现隐含的社区结构。Gao 等(2013)从通话数据中提取通话流与人群移动流可视化,并进行社区划分。Zhang 等(2012)对出租车数据进行 OD 流聚类分析,找出聚类中心,添加起始点语义信息,发现 OD 流的语义,如车站—车站、商场—车站等。

目前 OD 流模式的研究偏向于出租车轨迹数据、人口迁移数据,需更多针对手机通话数据的 OD 流研究。OD 流的可视化研究方面存在不足,如何获得更加直观、动态的可视化 OD 流值得研究。

3.2.3 时间模式

轨迹在时间维具有周期性,这种周期性反映个体及群体出行规律,从而发现一些异常模式、识别城市土地利用类型、城市功能配置等。从时间角度对轨迹的研究主要有 3 个方面:①从个体、群体层

面研究不同时间尺度(如:日、周、月、季度、年等)轨迹变化规律,挖掘频繁模式;②结合锚点研究中的兴趣点,判断居住地、工作地;③根据特定区域人类活动的时序变化识别城市土地利用类型。

(1) 轨迹在不同时间尺度的研究有个体轨迹和群体轨迹。在日尺度上,个体轨迹基本遵循家—工作—家的模式,群体轨迹的动态分布反映了城市实时交通变化、城市功能区分布等。Ratti 等(2006)利用意大利米兰的手机通话数据,研究城市居民的日常活动变化情况,发现个体由城市周边进入中心区工作,下班后扩散至城市周边。在周尺度上,工作日的个体轨迹数量高于非工作日,其中星期日最低(Calabrese et al, 2011)。在更大尺度上,个体轨迹遵循简单的重复模式。Gonzalez 等(2008)研究 10 万个匿名手机用户为期 6 个月的轨迹,发现出行轨迹具有高度的时空规律,尽管出行方式各不相同,但都遵循简单的重复模式。这种不同时间尺度个体出行模式的内在相似性非常值得防疫应急响应、城市规划等研究借鉴。群体轨迹则反映了城市居民分布密度的季节、年际变化规律。Pulselli 等(2005)利用意大利手机数据研究城市居民时空活动,发现城市居民分布密度和移动规律,以及海岸区域居民分布密度的季节变化现象。

(2) 根据个体轨迹遵循家—工作—家的规律,结合轨迹的兴趣点、时间,可以判断兴趣点是居住地或工作地(Calabrese et al, 2013)。Yuan 等(2011)以中国哈尔滨为例,利用手机数据集提取兴趣点,结合时间特征判断居住地、工作地。

(3) 不同城市土地利用类型对应着不同的社会功能,如住宅区、工业区、商业区等,但这种差异不能通过遥感影像解译判别。而特定区域活动(人口、通话)的时序变化具有特定的模式,可用于识别社会功能不同的区域。Pei 等(2014)利用新加坡手机通话数据,识别住宅区、商业区、工业区、空地等城市土地利用类型。

轨迹数据研究中,锚点中用户居住地、工作地等;出行范围涉及用户出行交互的区域;轨迹形状反映用户的工作性质;OD 流反映用户的出发地、目的地;时间模式发现用户的出行规律,各方面都涉及用户的隐私问题。目前很多学者采取匿名化的方法来保护用户隐私(Ahas et al, 2010),但通过用户轨迹数据发现用户出行规律,可以推测出用户的身份。采取研究群体轨迹或轨迹定位空间低分辨率

的方法保护用户个人隐私(Ratti et al, 2006; Yuan et al, 2013),但又无法精确定位个人轨迹,挖掘更精准知识。因此如何在保护用户隐私的前提下,挖掘轨迹数据得到精准知识,也是今后亟需研究的方向。

4 轨迹数据在城市研究中的应用

通过对轨迹数据的研究,挖掘人类活动模式,进而了解人与人、人与环境之间的关系,在城市各领域广泛应用。目前,已应用于用户轨迹预测、城市动态景观、城市交通模拟和监控、城市功能单元识别以及城市其他领域。

4.1 用户出行预测

通过轨迹数据挖掘人类的活动模式,结合一些辅助信息可以预测用户轨迹。当前针对轨迹预测的研究主要包括两个方面:①研究轨迹可预测性条件;②预测用户轨迹。

很多学者关注人类活动轨迹是否可预测。Gonzalez等(2008)发现个体轨迹表面上是随机的,但人类轨迹在时空中具有规律性,即个体完成一次独立出行后,会以显著概率往返经常到访的地点,居民日常活动模式隐藏着高度的可预测性潜力。Song等(2010)发现人类活动有93%的可预测性。Zhao等(2011)使用离散熵来衡量离散轨迹的可预测性(越规律离散熵越低)。

发现轨迹的可预测性潜力后,人们通过轨迹数据挖掘用户的兴趣点、活动模式或结合历史轨迹预测用户轨迹或即将到访的地点。Cho等(2011)利用全球社交网络数据和手机数据研究人类活动模式,发现短距离时空中日常周期运动与人类经验结合紧密,而长途运动则与社交网络联系密切,因此开发了一种结合日常活动与社交网络的人类活动动力学模型,预测用户即将到访的地点。Di等(2012)利用个体和群体历史出行轨迹和区域特征(土地利用、兴趣点)预测个体轨迹,发现将群体活动行为整合在个体轨迹预测中能显著提高预测精度。Zhao等(2011)则把个人轨迹与群体活动轨迹相结合,使用动态贝叶斯网络来预测群体轨迹。Veloso等(2011)利用出租车历史数据在给定时间、天气以及前一个下客点类型的情况下,预测下一个上客点。齐观德等(2013)使用出租车历史轨迹数据,利用空车到达时间间隔的概率分布推断乘客等候时间的概率分布,从而预测乘客在某时某地等候出租车的

时间,准确率平均为84.7%。

4.2 城市居民出行动态景观

通过不同时段手机、出租车、智能卡等的使用,可以反映城市人群的活动轨迹,揭示城市人口在时空中的动态分布、活动强度及其时空动态演变,即城市居民出行动态景观。人类活动轨迹数据可以展示城市人口的动态分布;并揭示一些地理现象,发现城市热点区域。

(1) 轨迹数据提取的人类活动轨迹,有效展示了时空环境中城市人口的动态分布。通过手机通话数据反映城市人口的实时动态分布,进而监测城市居民活动(Pulselli et al, 2005; Marchettini et al, 2010)。Sevtsuk等(2010)利用手机通话数据发现不同时段城市基站间人群移动性的变化,并使用人口统计学、经济、建筑环境等指标对差异进行解释。

(2) 轨迹在时空中的从聚模式和周期性模式,揭示了城市居民活动的演化规律及城市地理现象,为城市规划、基础设施配置提供支持。Ratti等(2006)分析手机数据在不同时段的空间分布,发现城市居民职住分离的现象。此外,城市中的热点聚集区、社区结构等也可以通过轨迹数据分析得到(桂智明等, 2012; Giannotti et al, 2007; Lee et al, 2007)。Guo等(2010)通过车辆轨迹网络划分,发现城市内部联系紧密的区域。

4.3 城市交通模拟和监控

如何高效组织、管理城市交通一直是城市管理者关注的重点,因此通过有效的途径对城市交通进行模拟和监控,反映城市真实的交通状况,并对异常情况应急响应至关重要。如今通信、网络等技术的发展产生了大量轨迹数据,城市层次上群体轨迹的动态变化反映城市居民的活动情况,为城市交通监测、应急响应等提供新的途径。目前车辆GPS数据、手机数据等轨迹数据均可用于城市交通模拟与监控,发现应对异常交通情况(秦萧等, 2013)。

通过车辆GPS数据、手机数据或两者相结合的方式,可以对城市交通进行模拟与监控。①利用车辆GPS轨迹数据进行实时交通监管、路线导航是最常用的方法。Tu等(2010)将时空离散点连接成时空路径,将其切分为固定时段的路网快照,分析车辆速度和分布,得出随时间变化的路网信息。De等(2008)根据60万辆私家车的GPS轨迹数据推理出每隔3分钟意大利城市高速路以及主干街道路网的交通流速。②通过手机数据获取群体活动的

动态变化,模拟监控城市实时交通是近几年新兴的研究手段。Ratti(2007)根据展览场所实时的手机流量强度、交通变化数据,建立实时手机数据映射的城市地图。Qi等(2013)利用实时手机数据来模拟交通流量,将移动电话数据转化为交通数据,动态展示城市居民分布。③通过车辆GPS数据与手机数据结合,Hu等(2009)使用手机和出租车数据模拟城市人口的动态轨迹,通过数据融合和空间分析对城市人口旅游行为建模,以缓解城市交通拥堵。Calabrese等(2011)将手机、车辆数据结合,在城市监测平台上展示交通状况,及外国人的运动状态。

利用轨迹数据可监测城市交通,同时可以发现异常情况,及时疏导交通或应对公共突发事件。Kanoulas等(2006)通过分析车辆GPS轨迹数据发现拥堵路段及交通异常现象,为城市交通管理提供支持。Pang等(2011)使用出租车数据监控不可预料的交通行为。Barria等(2011)根据泰国高速路的视频数据,用统计方差对交通异常进行探测并分类。

4.4 城市功能单元识别

城市规划是城市发展的指南,但在发展过程中,某些区域真实情况与城市规划有所出入,因此及时了解真实的城市发展动态,并进行相应的规划调整非常重要。遥感图像解译作为了解真实土地利用现状的重要途径,也无法识别人类活动产生的不同城市功能单元。而轨迹数据蕴含着丰富的模式,不同城市功能区的人流变化模式不同,识别这些模式可以弥补传统遥感图像解译在识别城市功能单元中的不足;其次通过轨迹数据对活动交流频繁的区域划分,可以对城市行政区边界进行有效验证。

根据轨迹数据蕴含的人类活动模式,可以区分传统遥感图像解译无法识别的住宅、商业、工业等城市功能单元(Pei et al, 2013)。Pan等(2013)利用出租车轨迹中上车、下车不同的模式所对应不同土地利用类型,选择与上车、下车相关的6种要素组合,进行土地利用分类,精度达到了95%,并发现土地利用类型变化的区域。Yuan等(2012)将GPS数据和POI(Point of Interest)数据相结合,计算北京各区域中属于某功能区的概率,划分城市功能区。对比轨迹数据中活动交流频繁的区域与行政区边界,可以发现有趣的现象。在城市尺度上,Calabrese等(2011)发现根据通话模式划分的社区与地理界限不完全一致,说明除了地理相邻性,还有文化、经济等因素将人们联系在一起。但是在国家尺度上,Guo

(2009)利用人口迁移数据进行全国性的区域划分,结果与行政区边界不谋而合。Kang等(2013)对新加坡出租车轨迹数据进行社区划分,发现同一社区内出租车轨迹远多于社区之间的轨迹。隋正伟等(2013)利用中国签到数据提取个体在城市间的移动轨迹,通过复杂网络的划分方法,发现中国城市体系中,部分城市的总体格局区域边界与行政边界高度吻合。

4.5 其他方面的应用

轨迹数据在上述4种城市方面的应用之外,还可用于城市公共卫生(Guo, 2007)、城市公共安全(Fang et al, 2013)、城市防灾减灾(Gelernter et al, 2011, 2013)、城市旅游管理(黄潇婷等, 2011; Ahas et al, 2007)、城市居民健康(关美宝等, 2013)、城市信息推送商业服务等方面。

人群间的交互与人群时空移动,是决定流行病传播的重要影响因素之一。Pindolia等(2012)使用手机通话数据结合疟疾传播图,揭示国内人口流动模式对疟疾传播的影响,提出相关控制防御机制。轨迹数据反映的人类活动模式往往与城市特定的社会事件关系紧密。Calabrese等(2010)使用手机通话的轨迹数据,结合特定社会事件,分析人群目的地与社会事件的关系,为应对突发事件及缓解拥塞提供决策辅助信息流。轨迹数据在城市防灾减灾、城市旅游管理、信息推送、商业服务等一系列与人类活动息息相关的城市研究中被广泛应用,限于篇幅,不一一详述。

5 结论与讨论

人类活动行为可通过各类传感器转换为海量的轨迹数据,这些轨迹数据是研究人类行为的基础素材。因为轨迹数据反映的人类行为模式,包括时空属性与网络属性,对时空属性的研究反映人类活动模式,而网络则反映人类社交关系,对空间以及空间中的网络进行研究可以反映地理环境与人类行为的相互影响。因此本文关注反映人类活动模式的人类活动轨迹的研究。按照轨迹数据的采样方式和驱动因素,将轨迹数据分为3种类型:基于时间采样、基于位置采样、基于事件触发采样,各种轨迹外在形式、表达模型、优缺点也因为采样方式的不同而存在差异。即便如此,各类轨迹数据均由起始点、锚点和一般节点等构成。而针对轨迹的相

关研究主要集中在锚点、出行范围、轨迹形状模式、OD流模式、时间模式等方面,其研究成果可揭示人类活动轨迹在时间、空间的从聚模式、周期性等。上述模式及特征的研究对人类活动模式进行识别、进而对用户轨迹预测、城市动态景观、城市交通、识别城市功能单元、城市公共卫生、城市公共安全、城市防灾减灾、旅游管理、商业服务等方面提供支持。

目前,针对人类活动轨迹数据的研究虽然取得若干突破性的成果,但仍存在一些不足,同时也是相关研究未来的方向。①由于轨迹数据表达形式、产生机理与传统空间数据不同,带来的时空耦合、高维、空间关系复杂、数据量大等特征需要更为高级的理论和方法,同时需要合理设计算法,提高运算效率,支持实时数据分析反馈。②目前的研究在分析相似用户轨迹和活动模式时,轨迹的几何特征与语义信息的结合存在不足。③当前研究在人类活动轨迹数据的可视化方面需要改善,产生更为直观、动态、实时更新显示的可视化效果。④轨迹数据的用户隐私问题,导致各类轨迹数据获取困难,数据共享不足。如何在保护用户隐私的前提下,尽可能地详细记录人类活动信息,为研究提供更多数据值得关注。

总体来说,针对人类行为的研究方兴未艾,而以智能卡为代表的泛在传感器所记录的人类活动的数据是目前尚未开发的一座宝藏,它的出现正如当初遥感数据的出现使得自然地理学研究出现跨越性的发展一样,记录人类行为的智能卡数据同样会在人文—经济地理学产生深刻变革。由于其在表达形式、产生机理等方面的特点给我们提出了前所未有的挑战,而地理信息科学作为处理传统空间数据的理论,正处在变革的前沿。

参考文献(References)

- 邓毛颖, 谢理. 2000. 广州市居民出行特征分析及交通发展的对策. 城市规划, 24(11): 45-49. [Deng M Y, Xie L. 2000. The characteristics of the trips of the local residents and the transport policy in GuangZhou. City Planning, 24(11): 45-49.]
- 关美宝, 郭文伯, 柴彦威. 2013. 人类移动性与健康研究中的时间问题. 地理科学进展, 32(9): 1344-1351. [Kwan M P, Guo W B, Chai Y W. 2013. Temporally integrated human mobility and health research. Progress In Geography, 32(9): 1344-1351.]
- 桂智明, 向宇, 李玉鉴. 2012. 基于出租车轨迹的并行城市热点区域发现. 华中科技大学学报: 自然科学版, 40(S1): 187-190. [Gui Z M, Xiang Y, Li Y J. 2012. Parallel discovering of city hot spot based on taxi trajectories. Journal of Huazhong University of Science and Technology: Natural Science Edition, 40(S1): 187-190.]
- 黄潇婷, 马修军. 2011. 基于GPS数据的旅游者活动节奏研究. 旅游学刊, 26(12): 26-29. [Huang X T, Ma X J. 2012. Study on tourists' rhythm of activities based on GPS data. Tourism Tribune, 26(12): 26-29.]
- 龙瀛, 张宇, 崔承印. 2012. 利用公交刷卡数据分析北京职住关系和通勤出行. 地理学报, 67(10): 1339-1352. [Long Y, Zhang Y, Cui C Y. 2012. Identifying commuting pattern of Beijing using bus smart card data. Acta Geographica Sinica, 67(10): 1339-1352.]
- 罗典, 甘勇华. 2010. 城市空间发展对居民出行特征的影响研究: 以广州为例. 交通与运输: 学术版, 1: 11-14. [Luo D, Gan Y H. 2010. Study about impact of urban area development on residents' travel characteristic: a case research on Guangzhou City. Traffic and Transportation, 1: 11-14.]
- 马静, 柴彦威, 张文佳. 2009. 北京市居民购物出行影响因素的空间分异. 经济地理, 29(12): 2006-2011. [Ma J, Chai Y W, Zhang W J. 2009. A study on shopping behavior of Beijing residents: the spatial differentiation of influencing factors. Economic Geography, 29(12): 2006-2011.]
- 齐观德, 潘遥, 李石坚, 等. 2013. 基于出租车轨迹数据挖掘的乘客候车时间预测. 软件学报, 24(S2): 14-23. [Qi G D, Pan Y, Li S J, et al. 2013. Predicting passengers' waiting time by mining taxi traces. Journal of Software, 24(S2): 14-23.]
- 秦萧, 甄峰, 熊丽芳, 等. 2013. 大数据时代城市时空行为研究方法. 地理科学进展, 32(9): 1352-1361. [Qin X, Zhen F, Xiong L F, et al. 2013. Methods in urban temporal and spatial behavior research in the Big Data Era. Progress in Geography, 32(9): 1352-1361.]
- 曲大义, 于仲臣, 庄劲松, 等. 2001. 苏州市居民出行特征分析及交通发展对策研究. 东南大学学报, 31(3): 118-123. [Qu D Y, Yu Z C, Zhuang J S, et al. 2001. Analysis on the resident trip characteristics and study on the transport development policies in Suzhou. Journal of Southeast University, 31(3): 118-123.]
- 申悦, 柴彦威. 2013. 基于GPS数据的北京市郊区巨型社区居民日常活动空间. 地理学报, 68(4): 506-516. [Shen Y, Chai Y W. 2013. Daily activity space of suburban mega-community residents in Beijing based on GPS data. Acta Geographica Sinica, 68(4): 506-516.]
- 隋正伟, 邬伦, 刘瑜. 2013. 基于签到数据的城市间交互网络研究. 地理与地理信息科学, 29(6): 1-5. [Sui Z W, Wu

- L, Liu Y. 2013. Study on interactive network among Chinese cities based on the check-in dataset. *Geography and Geo-Information Science*, 29(6): 1-5.]
- 童晓君, 向南平, 朱定局. 2012. 基于出租车GPS数据的城市居民出行行为分析. *电脑与电信*, 1: 56-59. [Tong X J, Xiang N P, Zhu D J. 2012. The analysis of city dweller's travel choice behavior based on taxi GPS trajectory data. *Computer & Telecommunication*, 1: 56-59.]
- Ahas R, Aasa A, Mark Ü, et al. 2007. Seasonal tourism spaces in Estonia: case study with mobile positioning data. *Tourism Management*, 28(3): 898-910.
- Ahas R, Silm S, Järv O, et al. 2010. Using mobile positioning data to model locations meaningful to users of mobile phones. *Journal of Urban Technology*, 17(1): 3-27.
- Barria J A, Thajchayapong S. 2011. Detection and classification of traffic anomalies using microscopic traffic variables. *IEEE Transactions on Intelligent Transportation Systems*, 12(3): 695-704.
- Calabrese F, Di Lorenzo G, Liu L, et al. 2011. Estimating origin-destination flows using mobile phone location data. *IEEE Pervasive Computing*, 10(4): 36-44.
- Calabrese F, Diao M, Di Lorenzo G, et al. 2013. Understanding individual mobility patterns from urban sensing data: a mobile phone trace example. *Transportation Research Part C: Emerging Technologies*, 26: 301-313.
- Calabrese F, Pereira F C, Di Lorenzo G, et al. 2010. The geography of taste: analyzing cell-phone mobility and social events//Floreen P, Kruger A, Spasojevic M. *Pervasive computing*. Berlin, Germany: Springer: 22-37.
- Calabrese F, Ratti C, Colonna M, et al. 2011. Real-time urban monitoring using cell phones: a case study in Rome. *IEEE Transactions on Intelligent Transportation Systems*, 12(1): 141-151.
- Camargo S J, Robertson A W, Gaffney S J, et al. 2004. Cluster analysis of western North Pacific tropical cyclone tracks. The 26th conference on hurricanes and tropical meteorology. Miami, FL, May 3-7, 2004.
- Cho E, Wong K, Gnawali O, et al. 2011. Inferring mobile trajectories using a network of binary proximity sensors. The 8th annual IEEE communications society conference on Sensor, mesh and ad hoc communications and networks (SECON). Salt Lake, UT, June 27- 30, 2011.
- De F C, Roberto R, Gaetano V. 2008. Traffic estimation and prediction based on real time floating car data//IEEE. Proceedings of the 11th international IEEE conference on intelligent transportation systems. New York, NY: IEEE: 197-203.
- Demetra V C, Joy S, Lee G. 2003. The 2001 national household travel survey: a look into the travel patterns of older Americans. *Journal of Safety Research*, 34(4): 461-470.
- Di Lorenzo G, Reades J, Calabrese F, et al. 2012. Predicting personal mobility with individual and group travel histories. *Environment and Planning B*, 39(5): 838.
- Fang Z, Li Q, Li Q, et al. 2013. A space-time efficiency model for optimizing intra-intersection vehicle-pedestrian evacuation movements. *Transportation Research C: Emerging Technologies*, 31: 112-130.
- Gao S, Liu Y, Wang Y, et al. 2013. Discovering spatial interaction communities from mobile phone data. *Transactions in GIS*, 17: 463-481.
- García R C, López L P, Urios V. 2010. First description of migration and wintering of adult Egyptian Vultures *Neophron percnopterus* tracked by GPS satellite telemetry. *Bird Study*, 57(2): 261-265.
- Gelernter J, Balaji S. 2013. An algorithm for local geoparsing of microtext. *GeoInformatica*, 17(4): 635-667.
- Gelernter J, Mushegian N. 2011. Geo-parsing messages from microtext. *Transactions in GIS*, 15(6): 753-773.
- Giannotti F, Nanni M, Pinelli F, et al. 2007. Trajectory pattern mining. The 13th ACM SIGKDD international conference on knowledge discovery and data mining. San Jose, CA, August 12-15, 2007.
- Golledge R G, Stimson R J. 1997. *Spatial behavior: a geographic perspective*. New York, NY: Guilford Press.
- Gonzalez M C, Hidalgo C A, Barabasi A L. 2008. Understanding individual human mobility patterns. *Nature*, 453 (7196): 779-782.
- Guo D. 2007. Visual analytics of spatial interaction patterns for pandemic decision support. *International Journal of Geographical Information Science*, 21(8): 859-877.
- Guo D. 2009. Flow mapping and multivariate visualization of large spatial interaction data. *IEEE Transactions on Visualization and Computer Graphics*, 15(6): 1041-1048.
- Guo D, Liu S, Jin H. 2010. A graph-based approach to vehicle trajectory analysis. *Journal of Location Based Services*, 4 (3-4): 183-199.
- Guo D, Zhu X, Jin H, et al. 2012. Discovering spatial patterns in origin-destination mobility data. *Transactions in GIS*, 16(3): 411-429.
- Hu J, Cao W, Luo J, et al. 2009. Dynamic modeling of urban population travel behavior based on data fusion of mobile phone positioning data and FCD//Di L, Chen A. 17th international conference on geoinformatics. New York, NY: IEEE: 207-211.
- Kang C, Gao S, Lin X, et al. 2010. Analyzing and geo-visualizing individual human mobility patterns using mobile

- call records//Liu Y, Chen A. The 18th international conference on geoinformatics. Beijing, China: IEEE: 1-7.
- Kang C, Stanislav S, Liu Y, et al. 2013. Exploring human movements in Singapore: a comparative analysis based on mobile phone and taxicab usages. The 19th ACM SIGKDD international conference on knowledge discovery and data mining. Chicago, IL, August 11, 2013.
- Kanoulas E, Du Y, Xia T, et al. 2006. Finding fastest paths on a road network with speed patterns. The 22nd international conference on data engineering. Atlanta, GA, April 3-7, 2006.
- Kwan M P. 1999. Gender and individual access to urban opportunities: a study using space-time measure. *The Professional Geographer*, 51(2): 210-227.
- Kwan M P, Lee J. 2003. Geovisualization of human activity patterns using 3D GIS: a time- geographic approach// Goodchild M F, Janelle D G. Spatially integrated social science. examples in best practice. Oxford, UK: Oxford University Press: 48-66.
- Lee J G, Han J, Whang K Y. 2007. Trajectory clustering: a partition-and-group framework. ACM SIGMOD International conference on management of data. Beijing, China, June 12-14, 2007.
- Li X, Han J, Kim S, et al. 2007. Roam: Rule-and motif-based anomaly detection in massive moving object data sets// Apte C, Liu B, Parthasarathy S, et al. Proceedings of the seventh siam international conference on data mining. Philadelphia, PA: Siam: 273-284.
- Liu L, Andris C, Ratti C. 2010. Uncovering cabdrivers' behavior patterns from their digital traces. *Computers, Environment and Urban Systems*, 34(6): 541-548.
- Liu Y, Sui Z, Kang C, et al. 2014. Uncovering patterns of inter-urban trip and spatial interaction from social media check-in data. *PloS One*, 9(1): e86026.
- Marchettini N, Pulselli R M, Tiezzi E B P. 2010. An innovative survey of urban systems dynamics: the evidence of the MoTo project//Brescia C A, Hernandez S, Tiezzi E. The sustainable city VI: urban regeneration and sustainability, 129: 97.
- Nanni M. 2002. Clustering methods for spatio-temporal data. Pisa, Italy: University of Pisa.
- Pan G, Qi G, Wu Z, et al. 2013. Land-use classification using taxi GPS traces. *IEEE Transactions on Intelligent Transportation Systems*, 14(1): 113-123.
- Pang L X, Chawla S, Liu W, et al. 2011. On mining anomalous patterns in road traffic streams//Tang J, King I, Chen L, et al. Advanced data mining and applications. Berlin, Germany: Springer: 237-251.
- Pei T, Gong X, Shaw S L, et al. 2013. Clustering of temporal event processes. *International Journal of Geographical Information Science*, 27(3): 484-510.
- Pei T, Sobolevsky S, Ratti C, et al. 2014. A new insight into land use classification based on aggregated mobile phone data. *International Journal of Geographical Information Science*, doi: 10.1080/13658816.2014.913794.
- Phithakkitnukoon S, Horanont T, Di Lorenzo G, et al. 2010. Activity-aware map: identifying human daily activity pattern using mobile phone data//Salah A A, Gevers T, Sebe N, et al. Human Behavior Understanding. Berlin, Germany: Springer: 14-25.
- Pindolia D K, Garcia A J, Wesolowski A, et al. 2012. Human movement data for malaria control and elimination strategic planning. *Malaria Journal*, 11(1): 205.
- Pulselli R M, Pulselli F M, Ratti C, et al. 2005. Dynamics and evolution of urban patterns: the evidence of the mobile landscape project//Tiezzi E, Brebbia C A, Jorgensen S E, et al. Ecosystems and sustainable development V. Ashurst, UK: Wit Press: 597-603.
- Qi G Q, Wu J P, Du Y M. 2013. Research on the traffic simulation platform based on the real-time mobile phone data. *Applied Mechanics and Materials*, 253: 1365-1368.
- Ratti C, Williams S, Frenchman D, et al. 2006. Mobile landscapes: using location data from cell phones for urban analysis. *Environment and Planning B*, 33(5): 727-748.
- Ratti C. 2007. Mobile landscape: graz in real time. *Lecture Notes in Geoinformation and Cartography*, 5: 433-444.
- Rekimoto J, Miyaki T, Ishizawa T. 2007. LifeTag: WiFi-based continuous location logging for life pattern analysis// Hightower J, Schiele B, Strang T. Location and context-awareness. Berlin, Germany: Springer: 35-49.
- Sevtsuk A, Ratti C. 2010. Does urban mobility have a daily routine: learning from the aggregate data of mobile networks. *Journal of Urban Technology*, 17(1): 41-60.
- Simini F, González M C, Maritan A, et al. 2012. A universal model for mobility and migration patterns. *Nature*, 484(7392): 96-100.
- Song C, Qu Z, Blumm N, et al. 2010. Limits of predictability in human mobility. *Science*, 327(5968): 1018-1021.
- Sun L, Lee D H, Erath A, et al. 2012. Using smart card data to extract passenger's spatio-temporal density and train's trajectory of MRT system. International workshop on urban computing, urbcomp 2012-held in conjunction with KDD 2012. Beijing, China: August 12, 2012.
- Tu W, Fang Z, Li Q. 2010. Exploring time varying shortest path of urban OD Pairs based on floating car data//Liu Y, Chen A. 2010. 18th international conference on geoinformatics. New York, NY: IEEE: 1-6.

- Veloso M, Phithakkitnukoon S, Bento C. 2011. Urban mobility study using taxi traces. 2011. International workshop on trajectory data mining and analysis. Beijing, China: September 18, 2011.
- Wang G, Su J, Chu P C. 2003. Mesoscale eddies in the South China Sea observed with altimeter data. *Geophysical Research Letters*, 30(21): 2121.
- Yuan J, Zheng Y, Xie X. 2012. Discovering regions of different functions in a city using human mobility and POIs. The 18th ACM SIGKDD International conference on knowledge discovery and data mining. Beijing, China: August 12-16, 2012.
- Yuan Y, Raubal M. 2013. Measuring similarity of mobile phone user trajectories: a spatiotemporal edit distance method. *International Journal of Geographical Information Science*, doi: 10.1080/13658816.2013.8543 69.
- Yuan Y, Raubal M, Liu Y. 2011. Correlating mobile phone usage and travel behavior: a case study of Harbin, China. *Computers, Environment and Urban Systems*. 36(2): 118-130.
- Zhang D, Li N, Zhou Z H, et al. 2011. iBAT: detecting anomalous taxi trajectories from GPS traces. The 13th international conference on ubiquitous computing. Beijing, China: September 17-21, 2011.
- Zhang W, Li S, Pan G. 2012. Mining the semantics of origin-destination flows using taxi traces. The 14th international conference on ubiquitous computing. Pittsburgh, United States: September 5-8, 2012.
- Zhao N, Huang W, Song G, et al. 2011. Discrete trajectory prediction on mobile data//Du X Y, Fan W F, Wang JM, et al. *Web technologies and applications*. Berlin, Germany: Springer: 77-88.
- Zheng Y, Xie X. 2010. Learning location correlation from gps trajectories. The 11th IEEE international conference on mobile data management. Kansas City, MO, May 23-26, 2010.

A review on the classification, patterns and applied research of human mobility trajectory

LI Ting^{1,2}, PEI Tao¹, YUAN Yecheng¹, SONG Ci¹, WANG Weiyi^{1,2}, YANG Gege^{1,2}

(1. State Key Laboratory of Resources and Environmental Information System, Institute of Geographic Sciences and Natural Resources Research, CAS, Beijing 100101, China; 2. University of Chinese Academy of Sciences, Beijing 100049, China)

Abstract: Various sensors such as GPS units, mobile phones, public transportation passes, and bank cards record the trajectory of human activities. These massive trajectory data contain distribution pattern of human behavior in space and time. The study of trajectory data can reveal individual trajectory patterns, facilitate the understanding of characteristics of human dynamics, and thus support trajectory prediction, urban planning, traffic monitoring and the like. Therefore the study of trajectory data recorded by various sensors has become a focus of research at present. In this paper, we analyze the acquisition and expression of human activity trajectory. The trajectory of human activities can be classified into three broad categories according to the sampling methods and driving factors-through interval sampling, position sampling and event trigger sampling. The trajectory data are composed of origin points, destination points, anchor points and general nodes. The study of trajectory patterns is organized in accordance with anchor points, travel range, shape, origin-destination (OD) flow pattern, and temporal pattern. The results can reflect periodicity and clustering patterns of activities in space and time. On this basis, we summarize the application of human activity trajectory in urban studies from five aspects, including trajectory prediction, dynamic urban landscape delineation, urban traffic simulation and monitoring, urban functional unit identification, and other urban applications. We argue that exploring human activity patterns provides the basis for other studies in urban planning, urban traffic, public security, and so on.

Key words: trajectory characteristics; activity pattern; trajectory data